

Abstract

This project addresses the challenge of knowledge management at Jade Advisory by designing and implementing Ask-Jade, an intelligent question-answering system based on a Retrieval-Augmented Generation (RAG) architecture. The system transforms the organization's dispersed document library into a centralized and searchable knowledge base, enabling consultants to retrieve relevant project information efficiently. The ingestion pipeline relies on Docling, BGE-M3, and pgvector, orchestrated through LlamaIndex. A document management interface allows administrators to ingest, version, and monitor documents from a connected SharePoint instance. User and model management interfaces enable account administration and language model configuration without redeployment. Users can also select their preferred model directly from the chat interface. Evaluation results confirm the approach's relevance, achieving a hallucination rate below the target threshold alongside high faithfulness and helpfulness scores. The system supports English, French, and Arabic, with full answer traceability through source citations.

Keywords: Retrieval-Augmented Generation (RAG), LlamaIndex, BGE-M3, pgvector, Docling, knowledge management, large language model, vector search, multilingual processing.

Résumé

Ce projet répond au défi de la gestion des connaissances au sein de Jade Advisory en concevant et en implémentant Ask-Jade, un système de question-réponse basé sur une architecture RAG. Le système transforme la bibliothèque de documents dispersés en une base de connaissances centralisée et interrogeable. Le pipeline d'ingestion repose sur Docling, BGE-M3 et pgvector, orchestrés via LlamaIndex. Une interface de gestion documentaire permet d'ingérer, versionner et surveiller les documents depuis SharePoint. La gestion des utilisateurs et des modèles permet d'administrer les comptes et de configurer les modèles de langage sans redéploiement. Les utilisateurs peuvent également choisir leur modèle depuis l'interface de chat. Les résultats confirment la pertinence de l'approche, avec un taux d'hallucination inférieur au seuil cible et des scores élevés en fidélité et en utilité. Le système prend en charge l'anglais, le français et l'arabe, avec une traçabilité complète via des citations sources.

Mots clés : Génération Augmentée par Récupération (RAG), LlamaIndex, BGE-M3, pgvector, Docling, gestion des connaissances, modèle de langage, recherche vectorielle, traitement multilingue.